Escola de ÔMICAS
De 26/10 - 13/11
15 aulas · 3 semanas · 100% online

ABC

ISCB REGIONAL Student GROUP
222Brazil

Bioinformática & CADD

Da Ômica à Estrutura

A computação no planejamento de novos fármacos

Palestrante

DSc. Ana Luiza Martins Karl

E-mail: almk.karl@gmail.com

Institucional: anamartins@unifeso.edu.br

Conteúdo Programado

01

Introdução

02

Identificação de alvos

03

Obtenção de modelos

04

Preparação das estruturas

05

Simulações moleculares

06

Prática

01

Introdução

Como a bioinformática auxilia no desenvolvimento de fármacos?

Descoberta de Medicamentos







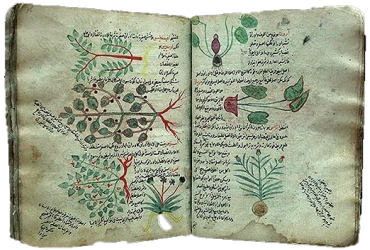




Sec XIX







Descoberta de Medicamentos

Sec XIX



1827

Friedrich Serturner: Síntese da morfina

Descoberta do éter como anestésico

1842



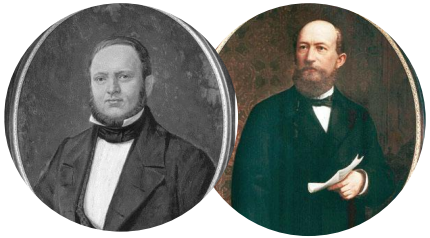


1878

Síntese do paracetamol

Friedrich Bayer e Felix Hoffman: Síntese da Aspirina

1897

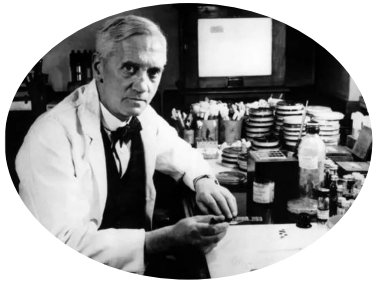


Descoberta de Medicamentos

Sec. XX

1928

Descoberta da Penicilina



1941

Gás mostarda no tratamento de linfoma

1942

Uso da Varfarina na área médica

1943

Descoberta da Estreptomicina

1960

Descoberta do Captopril

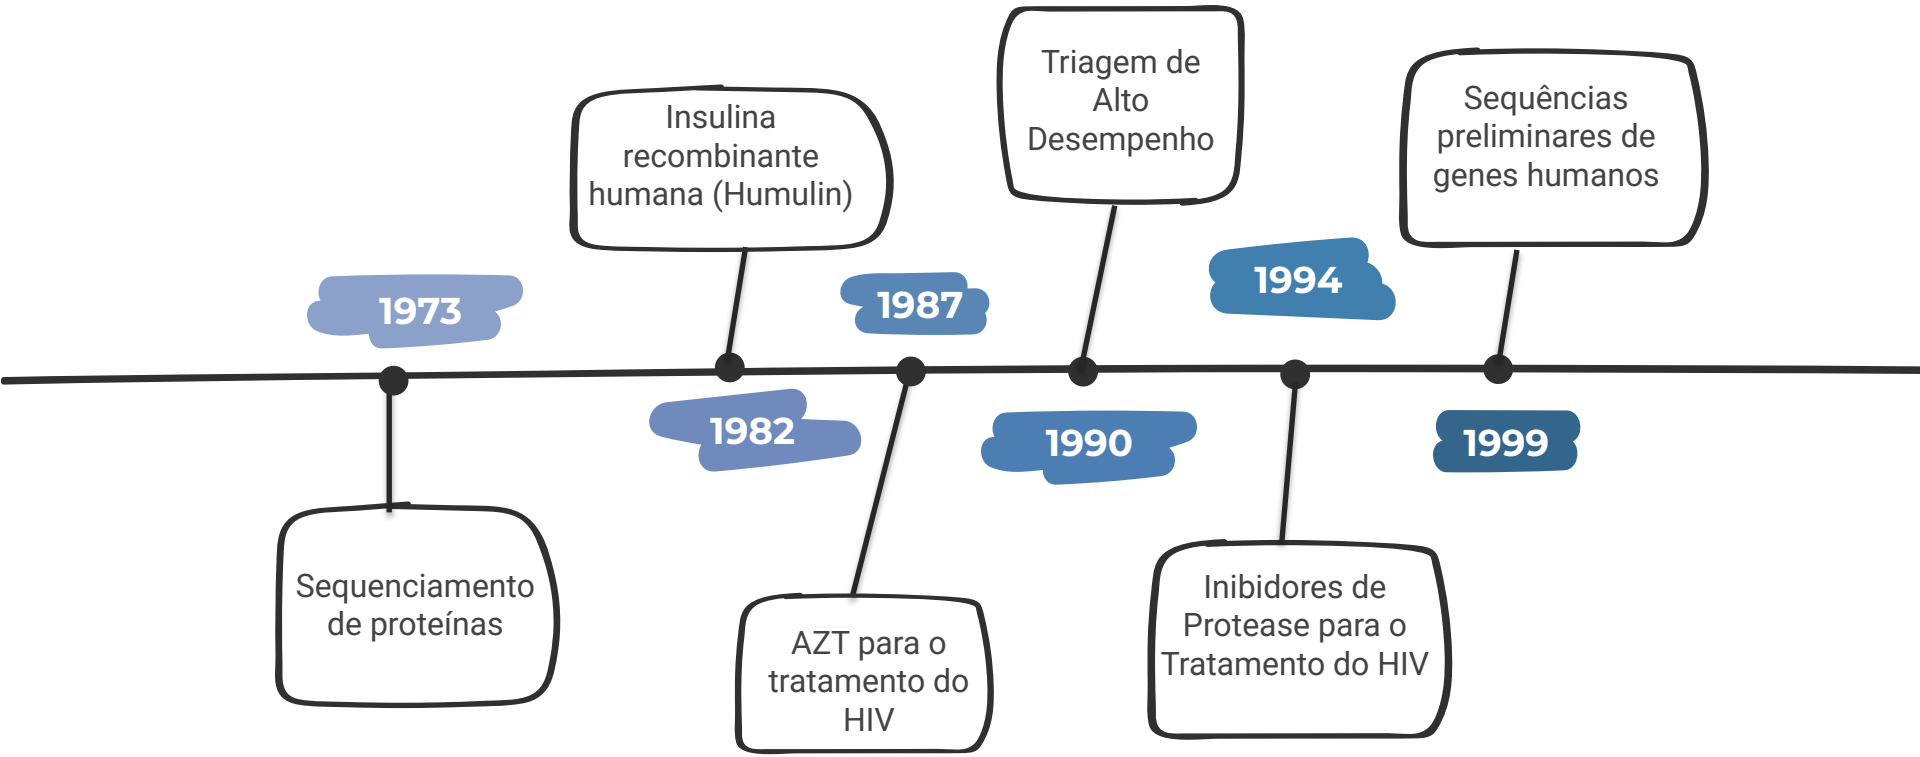
1962



1964

Introdução dos primeiros ensaios clínicos randomizados controlados

Descoberta de Medicamentos



Descoberta de Medicamentos

Sec. XXI

2000

Conclusão do projeto genoma humano

2001

Trastuzumabe: tratamentos com base em biomarcadores

2012

Nivolumab: imunoterapias

2013

CRISPR-Cas9

2017

Terapia com células CAR-T

2019

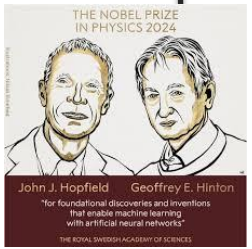
Vacina de mRNA – COVID-19

2021

AlphaFold 2

2024





O que mudou na ciência da descoberta de fármacos e vacinas?

ACASO

Descobertas Históricas

Alguns grandes marcos da medicina surgiram por eventos inesperados.

- **Varíola:** Jenner observa ordenhadoras resistentes.
- **Penicilina:** Placa de Fleming contaminada por fungo.
- **Éter:** Uso recreativo revela efeito anestésico.

O Paradigma Antigo

Dependência da sorte, longos períodos de observação passiva e alto risco experimental.



Hoje: Processo 100% Planejado - Desenvolvimento Racional de Fármacos

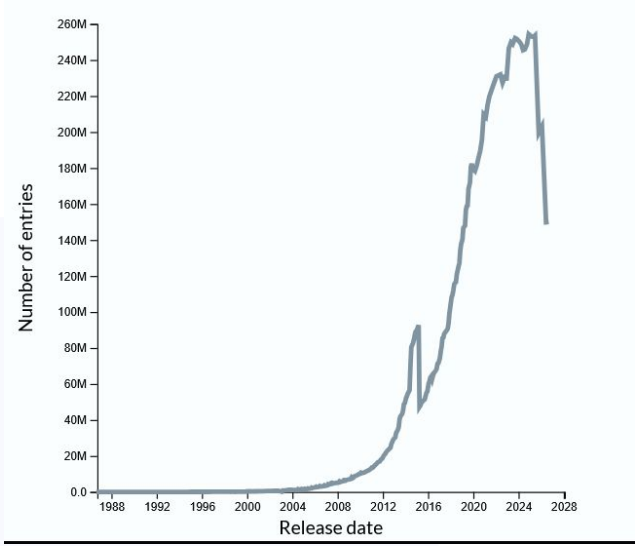
A ciência substituiu o acaso pelo **desenho inteligente**. Com o auxílio de ferramentas computacionais, novos fármacos e vacinas **são planejados** "sob medida" para seus alvos moleculares, direcionando os testes laboratoriais e **reduzindo o tempo e custo** de desenvolvimento.

O que mudou na ciência da descoberta de fármacos e vacinas?

- Avanços tecnológicos
- Integração com a computação
- Quantidade de dados disponíveis
- Capacidade de processamento
- Diminuição dos custos
- Decisões baseadas em conhecimento

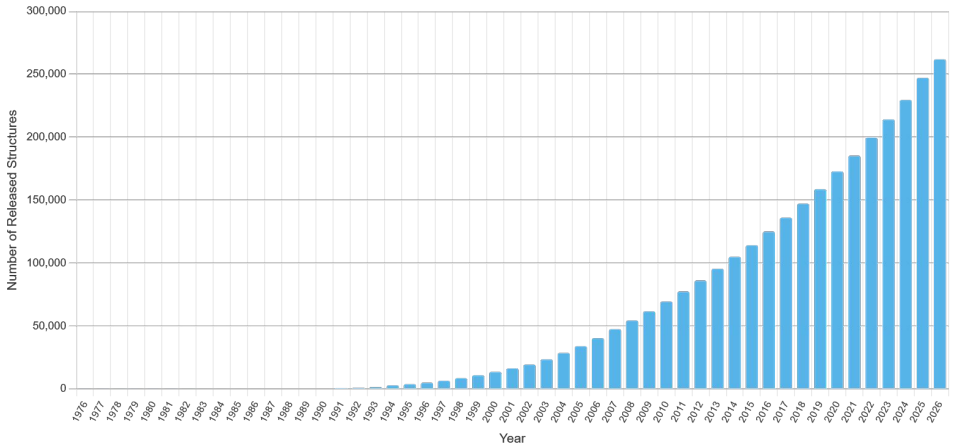
O que mudou na ciência da descoberta de fármacos e vacinas?

Sequências de proteínas depositadas no Uniprot



Fonte: https://www.ebi.ac.uk/uniprot/TrEMBLstats. Acesso em 28/10/2026

Estruturas de macromoléculas depositadas no PDB



Fonte: https://www.rcsb.org/stats/growth/growth-released-structures. Acesso em 28/10/2026

Desenvolvimento de fármacos

Visão Geral do Processo
Alto custo e baixa taxa de sucesso

Tempo Médio
10 - 15 Anos

Custo Estimado
~ € 1 Bilhão

Taxa de Sucesso
1 em 15.000

1. Pesquisa básica

Fase de Descoberta
Identificação de alvos moleculares e triagem inicial de compostos.

Tempo Estimado
2 a 5 Anos

Triagem Inicial
~ 15.000 compostos

2. Pré-Clínica

Segurança in vitro/vivo
Testes de toxicidade em modelos celulares e animais vivos.

Tempo Estimado
1 a 2 Anos

Seleção de *hits*
~ 250 candidatos

3. Fase Clínica

Testes em Humanos
Fases I, II e III para avaliar dosagem, eficácia e efeitos colaterais.

Tempo Estimado
5 a 10 Anos

Investimento Clínico
~ 70% do custo total

4. Aprovação

Aprovação e Mercado
Revisão rigorosa por agências como ANVISA, FDA ou EMA.

Tempo Estimado
1 a 2 Anos

Resultado Final
1 Fármaco Aprovado

Adaptado de: https://www.worksure.org/drug-development-process-from-discovery-to-patient-care/ Acesso em 10/08/2026

Desenvolvimento de fármacos

Visão Geral do Processo
Alto custo e baixa taxa de sucesso

Tempo Médio
10 - 15 Anos

Custo Estimado
~ € 1 Bilhão

Taxa de Sucesso
1 em 15.000

1. Pesquisa básica

Fase de Descoberta

Identificação de alvos moleculares e triagem inicial de compostos.

Tempo Estimado
2 a 5 Anos

Triagem Inicial
~ 15.000 compostos

2. Pré-Clínica

Segurança in vitro/vivo

Testes de toxicidade em modelos celulares e animais vivos.

Tempo Estimado
1 a 2 Anos

Seleção de *hits*
~ 250 candidatos

3. Fase Clínica

Testes em Humanos

Fases I, II e III para avaliar dosagem, eficácia e efeitos colaterais.

Tempo Estimado
5 a 10 Anos

Investimento Clínico
~ 70% do custo total

4. Aprovação

Aprovação e Mercado

Revisão rigorosa por agências como ANVISA, FDA ou EMA.

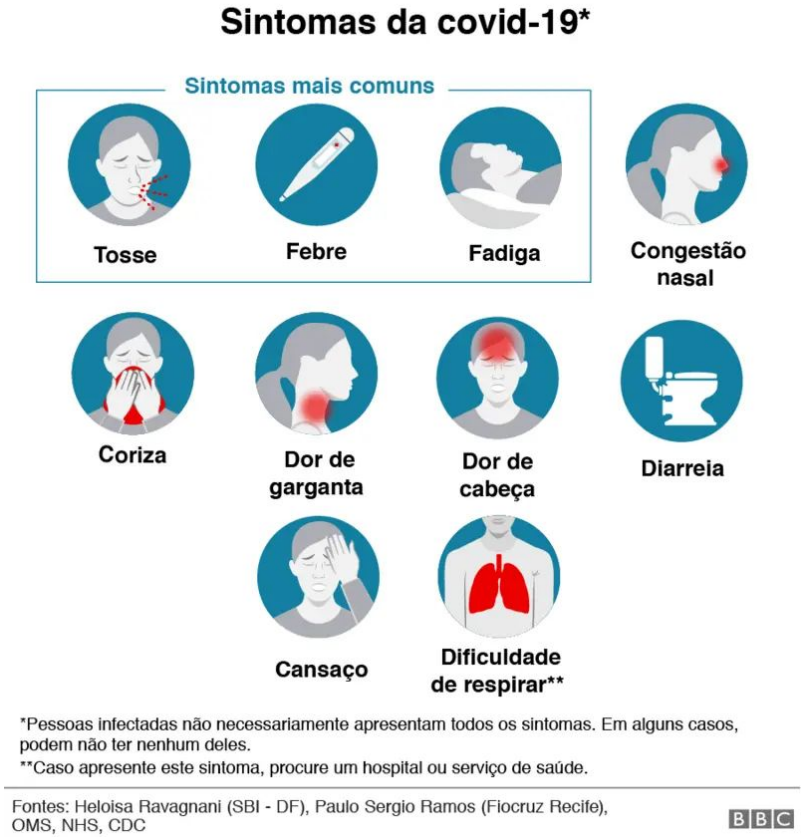
Tempo Estimado
1 a 2 Anos

Resultado Final
1 Fármaco Aprovado

Doença de interesse

Alvo molecular

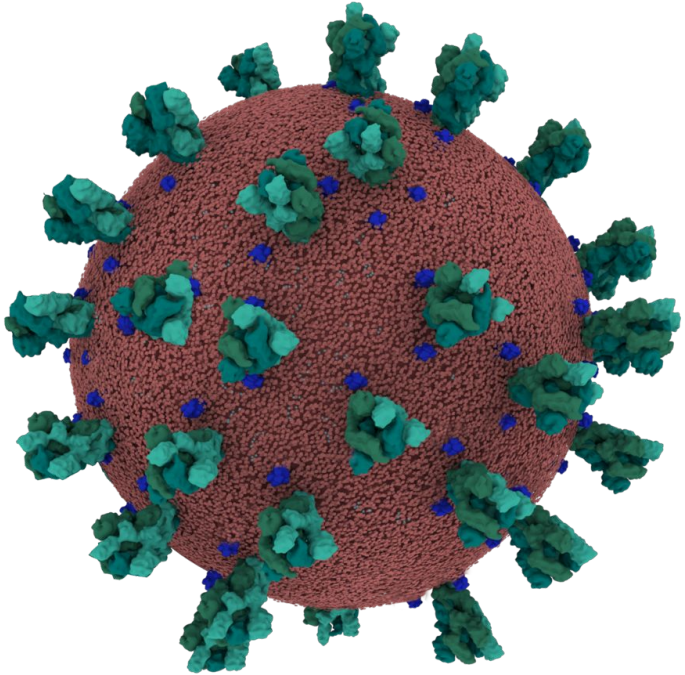
Modelagem Molecular



Doença de interesse

Alvo molecular

Modelagem Molecular



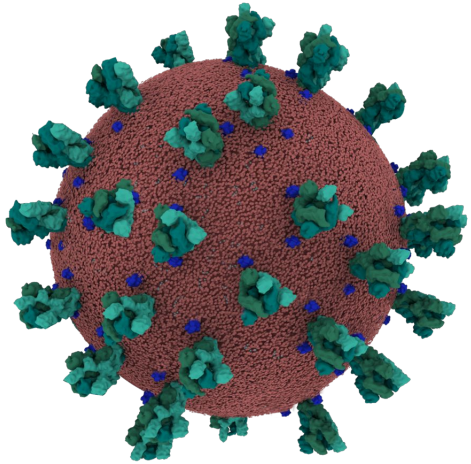
SARS-CoV-2

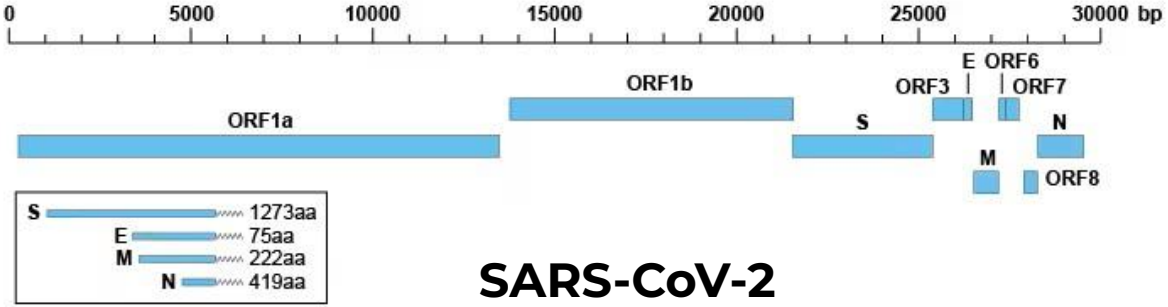
Fonte: COVID Resources, https://rcsb.org/news/feature/5e74d55d2d410731e9944f52

Doença de interesse

Alvo molecular

Modelagem Molecular



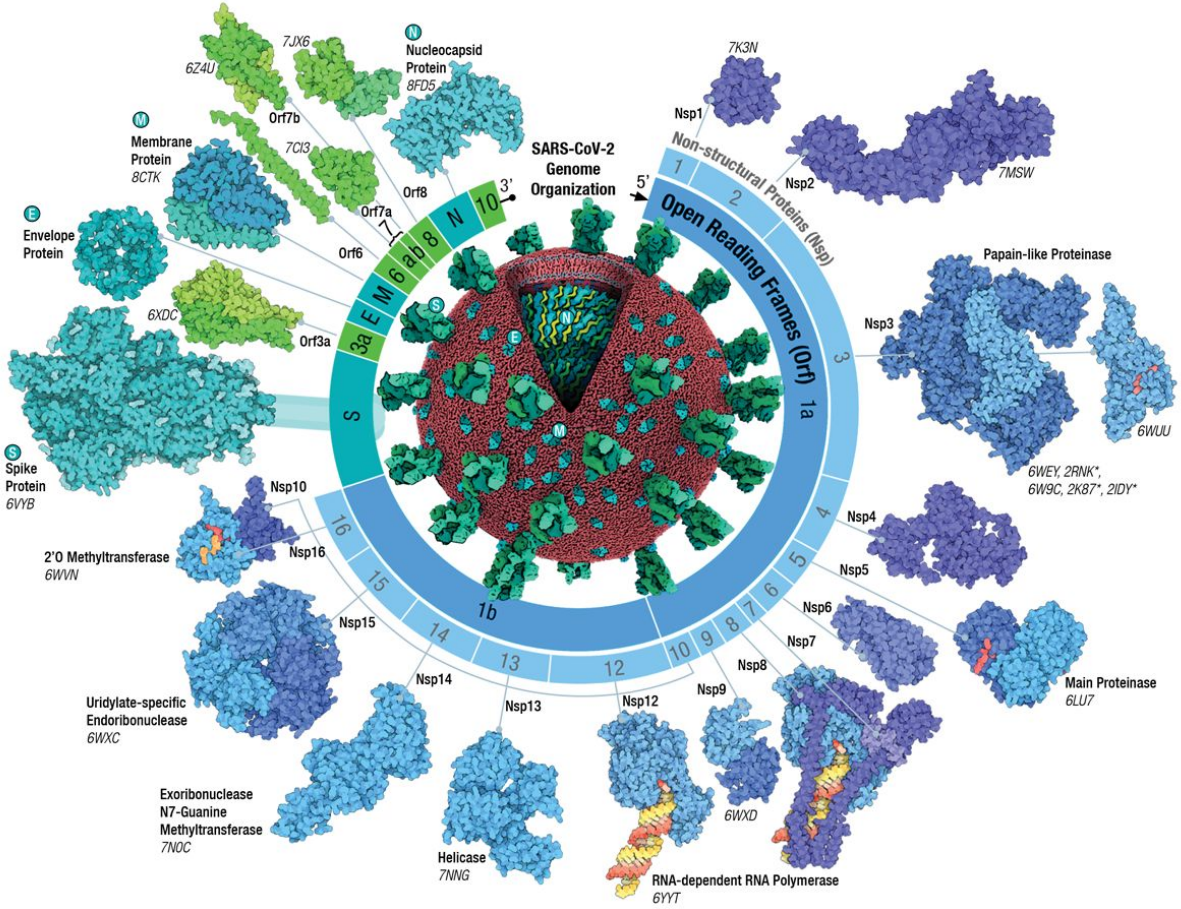


SARS-CoV-2

Doença de interesse

Alvo molecular

Modelagem Molecular

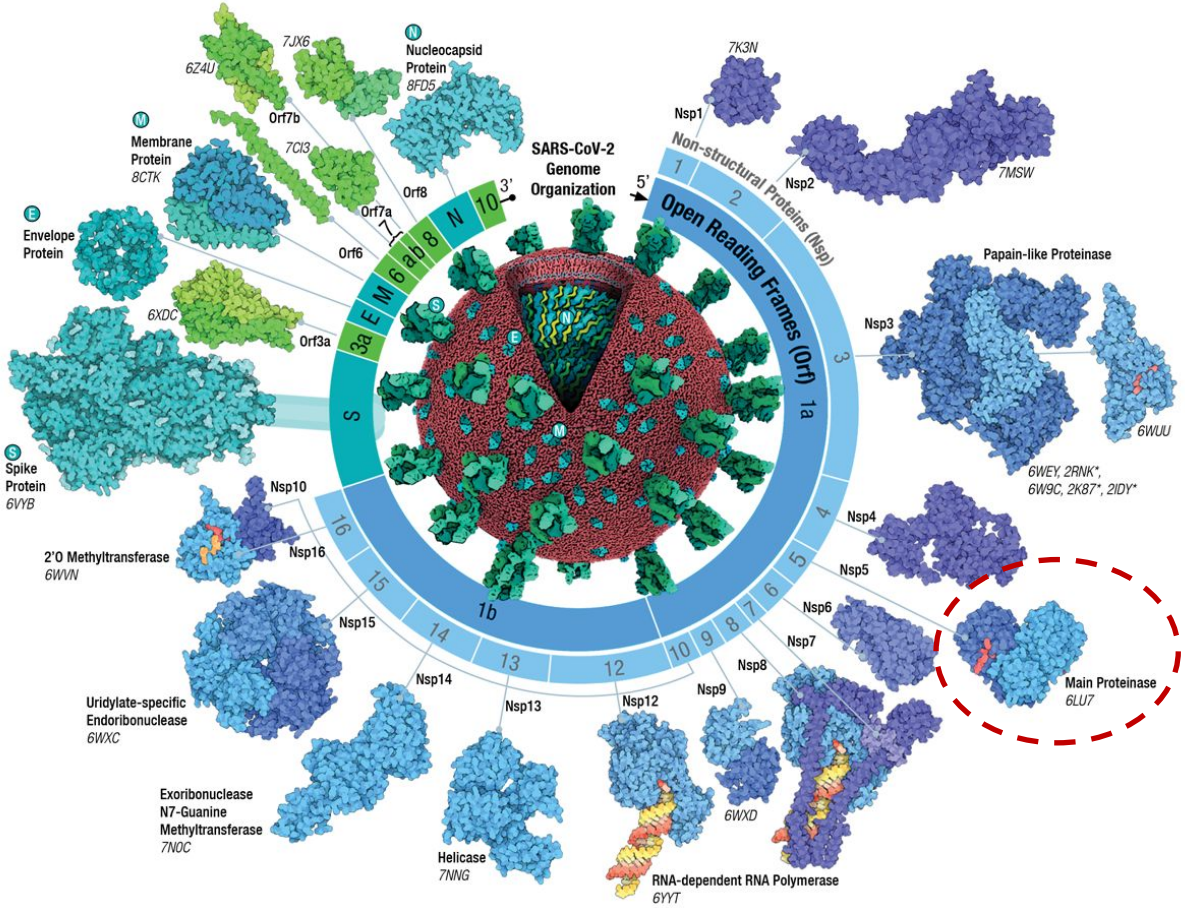


Fonte: COVID Resources, https://rcsb.org/news/feature/5e74d55d2d410731e9944f52

Doença de interesse

Alvo molecular

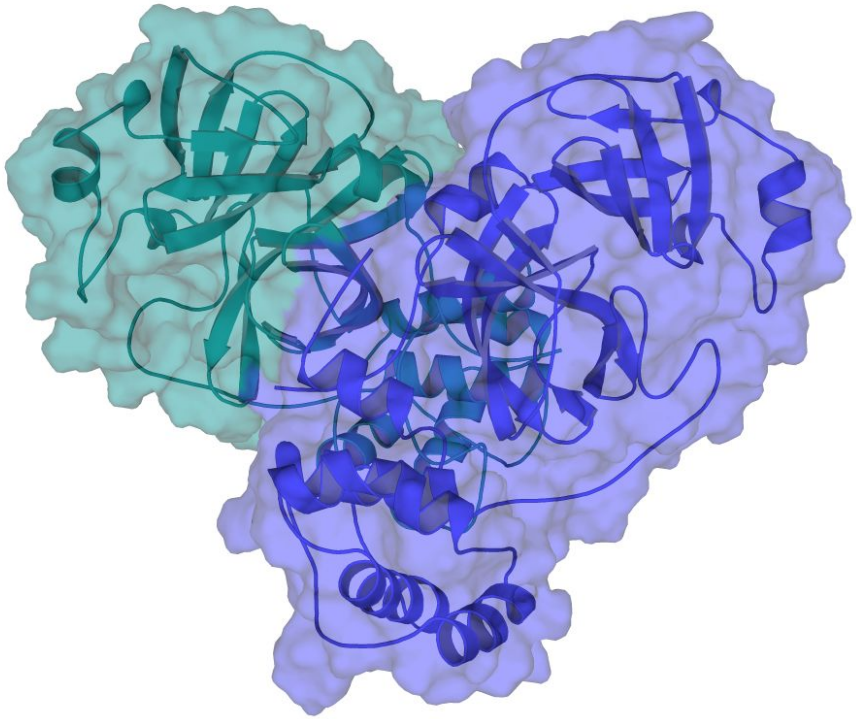
Modelagem Molecular



Doença de interesse

Alvo molecular

Modelagem Molecular

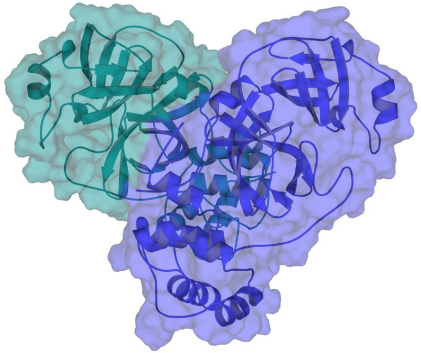


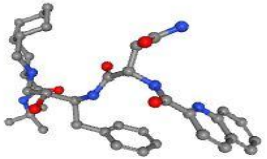
Protease principal

Doença de interesse

Alvo molecular

Modelagem Molecular





Alvo molecular (Receptor)

Pequenas moléculas Químicas (ligantes)

```
ATOM      1  N   MET A   1      12.850  -7.068  39.523  1.00 69.41           N
ATOM      2  CA  MET A   1      13.375  -6.064  40.442  1.00 70.57           C
ATOM      3  C   MET A   1      12.434  -5.800  41.618  1.00 68.11           C
ATOM      4  O   MET A   1      11.263  -6.193  41.598  1.00 61.92           O
ATOM      5  CB  MET A   1      13.690  -4.761  39.697  1.00 61.10           C
ATOM      6  CG  MET A   1      12.758  -4.456  38.532  1.00 55.09           C
```

Bioinformática e Modelagem Molecular

Bioinformática

Campo científico interdisciplinar que usa ferramentas de **computação, matemática e estatística** para analisar, armazenar e interpretar grandes volumes de dados biológicos.

Modelagem Molecular & Simulação

Conjunto de **técnicas computacionais** que utilizam **representações matemáticas** e **algoritmos** para simular/prever a estrutura, dinâmica e interações de moléculas, auxiliando na compreensão de processos químicos e biológicos.

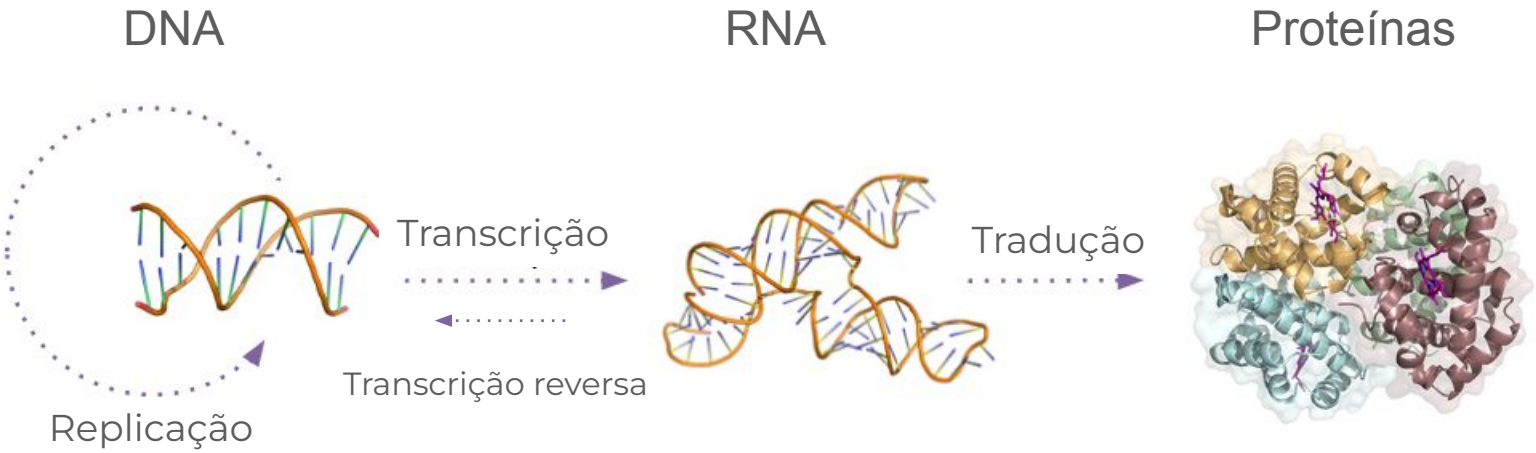
02

Identificação dos alvos

Como selecionar um alvo molecular?

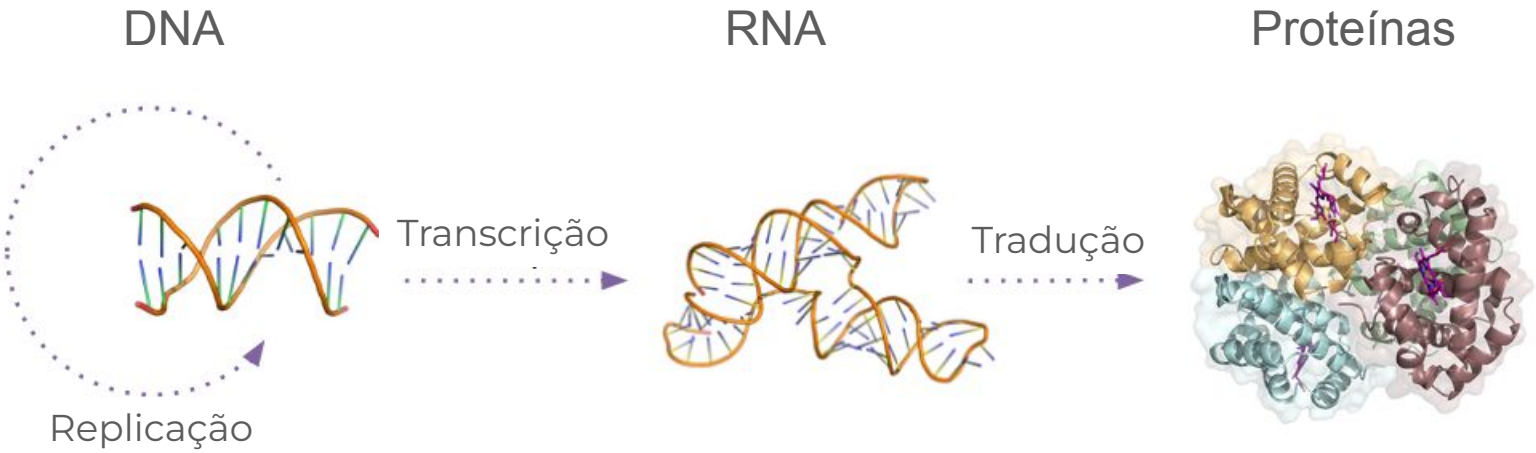
Relembrando...

Dogma Central da Biologia Molecular



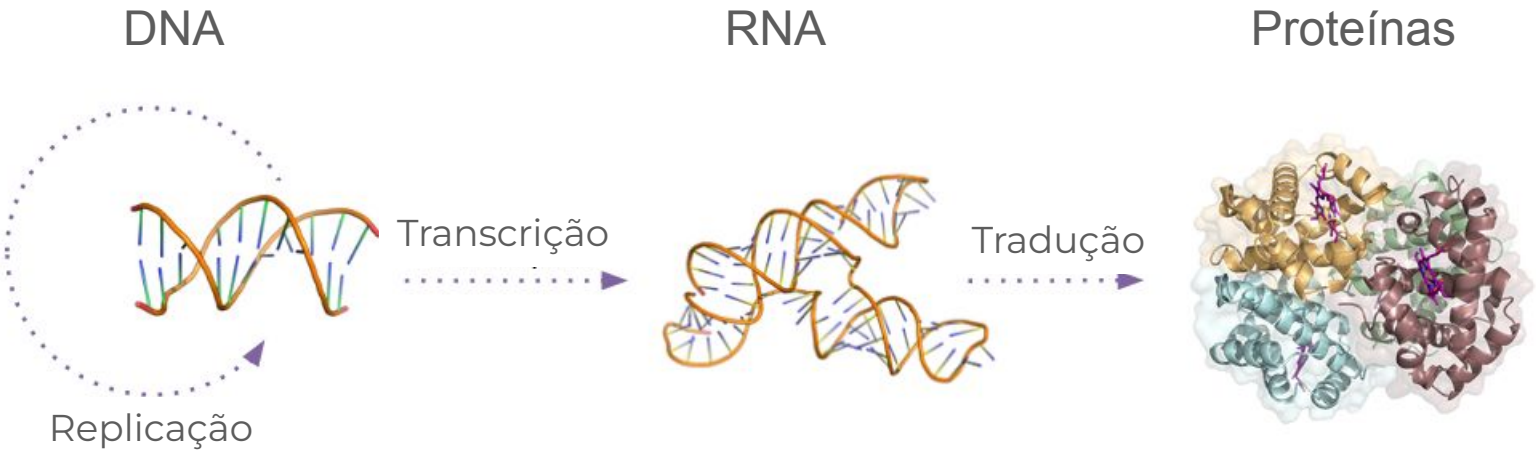
Relembrando...

Dogma Central da Biologia Molecular



Relembrando...

Dogma Central da Biologia Molecular



Relembrando...

Dogma Central da Biologia Molecular

RESEARCH ARTICLE | MOLECULAR BIOLOGY

Protein-templated synthesis of dinucleotide repeat DNA by an antiphage reverse transcriptase

PUJUAN DENG, HYUNBIN LEE, CARLO ARMIJO, HAOQING WANG, AND ALEX GAO Authors Info & Affiliations

SCIENCE • 16 Apr 2026 • Vol 392, Issue 6804 • pp. 1274-1281 • DOI: 10.1126/science.aed1656

Doença de Alzheimer



Cérebro saudável



Cérebro doente



Confusão de tempo e espaço



Problemas para acompanhar conversas



Perda de memória



Dificuldade com tarefas familiares



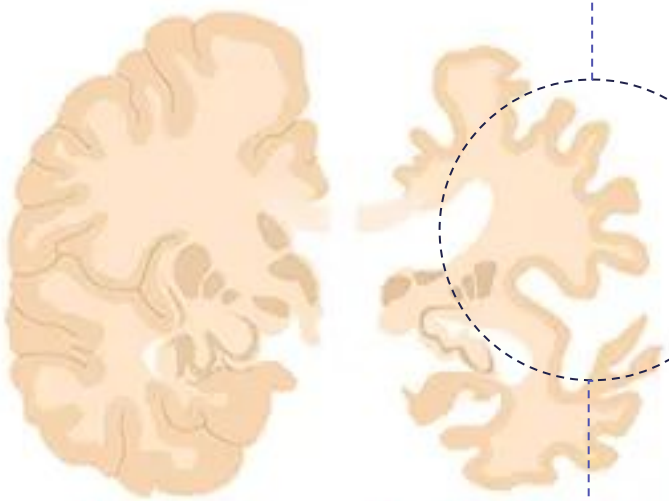
Perda de objetos



Mudanças de humor ou personalidade

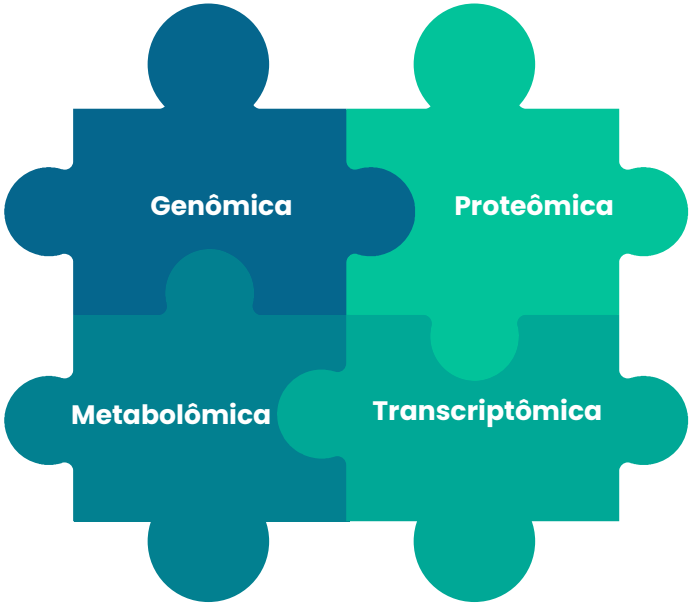
Adaptado de: https://www.apexhospitals.com/blogs-articles/understanding-alzheimers-disease-a-comprehensive-guide-for-caregivers-and-loved-ones

Doença de Alzheimer



- Neuroinflamação
- Deficiência de neurotransmissores
- Morte celular e autofagia
- Placas amiloides
- Disfunção mitocondrial
- Hiperfosforilação da proteína Tau
- Emaranhados neurofibrilares

Integração das ciências ômicas



1 **Mapeamento & Descoberta**
Identificação de genes associados a doenças e descoberta de novos biomarcadores.

2 **Validação Funcional**
Validação funcional de variantes genéticas e mapeamento detalhado de vias biológicas.

3 **Filogenômica**
Mapeamento de relações evolutivas e epidemiológicas

3 **Alvos Terapêuticos**
Proteínas-chave essenciais para o processo fisiopatológico ou a sobrevivência de patógenos

Pipeline de análises



Amostra biológica

Extração e isolamento do material genético

Sequenciamento

Geração de milhões de *reads* de leitura

Controle de qualidade

Filtragem de ruídos e adaptadores

Alinhamento e montagem

Reconstrução do genoma por algoritmos computacionais

Análises de dados

Análise de genes, variantes, biomarcadores, alvos terapêutivos, relação evolutiva, etc.

Pipeline de análises



Amostra biológica

Extração e isolamento do material genético

Sequenciamento

Geração de milhões de *reads* de leitura

Controle de qualidade

Filtragem de ruídos e adaptadores

Alinhamento e quantificação

Quantificação da abundância de *reads* de RNA-seq

Análises de dados

Expressão gênica em determinada condição ou tecido

03

Obtenção de modelos

Representando o sistema molecular

Obtenção dos modelos

As moléculas são descritas computacionalmente através de arquivos texto onde estão contidas as informações dos átomos que as compõem, assim como suas ligações.

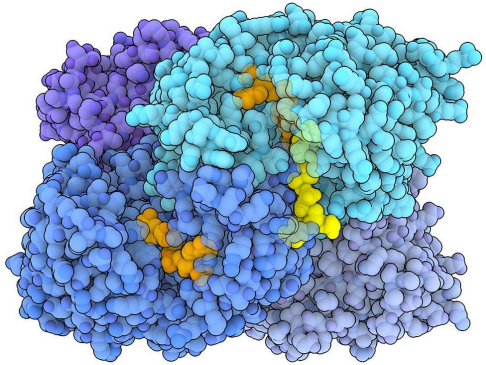
No caso dos sistemas biológicos, os formatos mais comuns dessa representação são:

- **PDB** (*Protein Data Bank file format*);
- Cif;
- MOL/MOL2;
- XYZ;
- Topology files (PSF, PRMTOP)

Obtenção dos modelos

As moléculas são descritas computacionalmente através de arquivos texto onde estão contidas as informações dos átomos que as compõem, assim como suas ligações.

```
ATOM      1  N   MET A   1      12.850  -7.068  39.523  1.00 69.41           N
ATOM      2  CA  MET A   1      13.375  -6.064  40.442  1.00 70.57           C
ATOM      3  C   MET A   1      12.434  -5.800  41.618  1.00 68.11           C
ATOM      4  O   MET A   1      11.263  -6.193  41.598  1.00 61.92           O
ATOM      5  CB  MET A   1      13.690  -4.761  39.697  1.00 61.10           C
ATOM      6  CG  MET A   1      12.758  -4.456  38.532  1.00 55.09           C
```



Obtenção dos modelos

261.584

Estruturas tridimensionais experimentalmente preditas no *Protein Data Bank**

208.433

Difração de Raios-x em Cristais

37.888

Microscopia eletrônica

14.869

Ressonância magnética nuclear

*Dados de 28 de outubro de 2026

Obtenção dos modelos

261.584

Estruturas tridimensionais experimentalmente preditas no *Protein Data Bank**

⚠️ Alto custo
⚠️ Condições experimentais difíceis de serem alcançadas

208.433

Difração de Raios-x em Cristais

37.888

Microscopia eletrônica

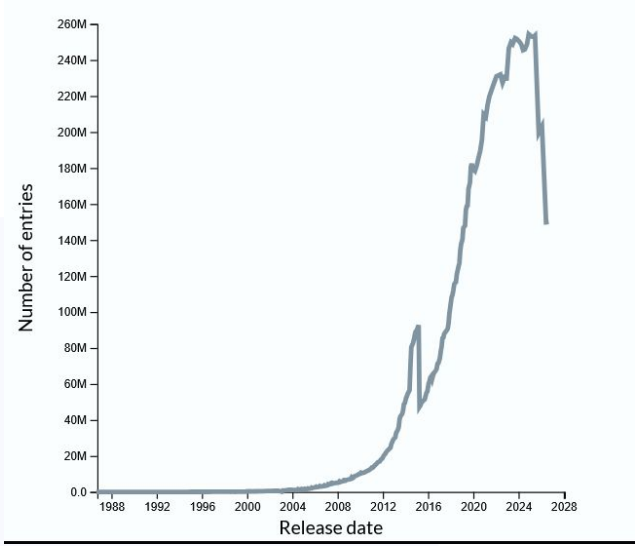
14.869

Ressonância magnética nuclear

*Dados de 28 de outubro de 2026

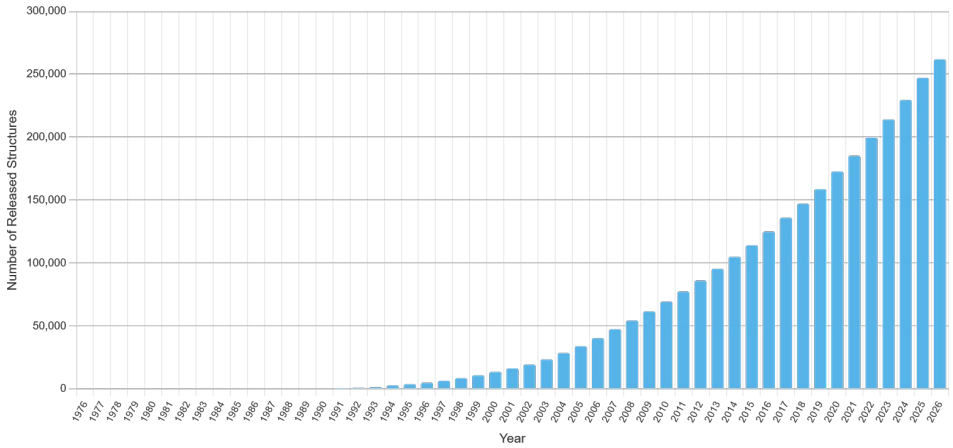
Obtenção dos modelos

Sequências de proteínas depositadas no Uniprot



Fonte: https://www.ebi.ac.uk/uniprot/TrEMBLstats. Acesso em 28/10/2026

Estruturas de macromoléculas depositadas no PDB



*Dados de 28 de outubro de 2026

Fonte: https://www.rcsb.org/stats/growth/growth-released-structures. Acesso em 28/10/2026

Métodos Computacionais de Predição

Modelagem tridimensional de estruturas proteicas

Postulado de Anfinsen (Hipótese Termodinâmica)

Toda a informação necessária para o enovelamento correto de uma proteína está contida de forma intrínseca em sua **sequência de aminoácidos**.

Sequências Primárias
Código linear de aminoácidos

Computação

Estrutura Tridimensional
Modelo funcional nativo (3D)

1. Entrada de Dados

A sequência linear de aminoácidos representa o ponto de partida físico-químico, contendo as instruções de dobramento.

2. Processamento & Saída

Algoritmos processam as restrições energéticas e traduzem o código unidimensional na estrutura funcional estável.

Métodos Computacionais de Predição

Modelagem tridimensional de estruturas proteicas

Template-based

Identidade de Sequência

Modelagem comparativa

>40%

identidade de sequência

Identidade de Sequência

Threading

<40%

identidade de sequência

Template-free

Fundamento

Ab-initio

Baseados em forças físicas

Fundamento

De novo

Baseados em dados empíricos

CASP

Critical Assessment of Protein Structure Prediction — competição global para a predição de estruturas de proteínas

Desde 1994 • 16 edições

Modeller

Método template-based

Modelagem por homologia que utiliza estruturas tridimensionais já conhecidas como moldes guia.

Robetta

Método ab initio

Predição estrutural realizada diretamente a partir da sequência de aminoácidos, sem necessidade de moldes.

AlphaFold

Google DeepMind • 2022

92,4%

Sucesso na predição

Acurácia disruptiva que revolucionou a biologia estrutural.

The Nobel Prize in Chemistry 2024



Ill. Niklas Elmehed © Nobel Prize Outreach

David Baker

Prize share: 1/2



Ill. Niklas Elmehed © Nobel Prize Outreach

Demis Hassabis

Prize share: 1/4



Ill. Niklas Elmehed © Nobel Prize Outreach

John M. Jumper

Prize share: 1/4

RCSB PDB PROTEIN DATA BANK

259,129 Structures from the PDB archive

1,062,058 Computed Structure Models (CSM)

Article

Highly accurate protein structure prediction with AlphaFold

https://doi.org/10.1038/s41586-021-03819-2

Received: 11 May 2021

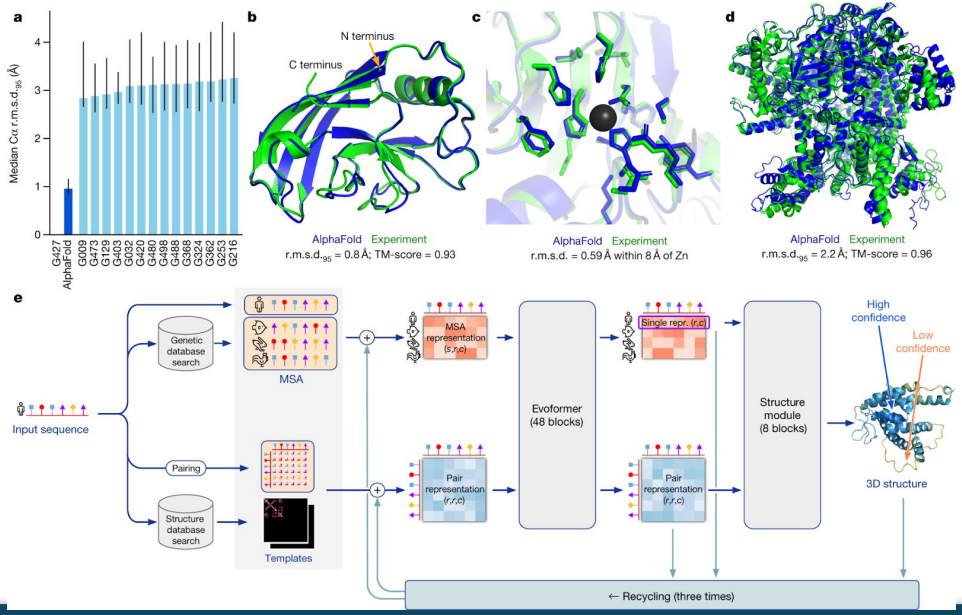
Accepted: 12 July 2021

Published online: 15 July 2021

Open access

Check for updates

John Jumper[1,4], Richard Evans[1,4], Alexander Pritzel[1,4], Tim Green[1,4], Michael Figurnov[1,4], Olaf Ronneberger[1,4], Kathryn Tunyasuvunakool[1,4], Russ Bates[1,4], Augustin Žídek[1,4], Anna Potapenko[1,4], Alex Bridgland[1,4], Clemens Meyer[1,4], Simon A. A. Kohl[1,4], Andrew J. Ballard[1,4], Andrew Cowie[1,4], Bernardino Romera-Paredes[1,4], Stanislav Nikolov[1,4], Rishub Jain[1,4], Jonas Adler[1], Trevor Back[1], Stig Petersen[1], David Reiman[1], Ellen Clancy[1], Michal Zielinski[1], Martin Steinegger[2,3], Michalina Pacholska[1], Tamas Berghammer[1], Sebastian Bodenstein[1], David Silver[1], Oriol Vinyals[1], Andrew W. Senior[1], Koray Kavukcuoglu[1], Pushmeet Kohli[1] & Demis Hassabis[1,4]



AlphaFold: metodologia

01

Entrada de dados

Recepção das sequências primárias de aminoácidos

02

Análise de sequências

Busca de homologia e alinhamento múltiplo (MSA)

03

Predição Inicial

Geração do modelo tridimensional preliminar

04

Aprimora-mento de estrutura

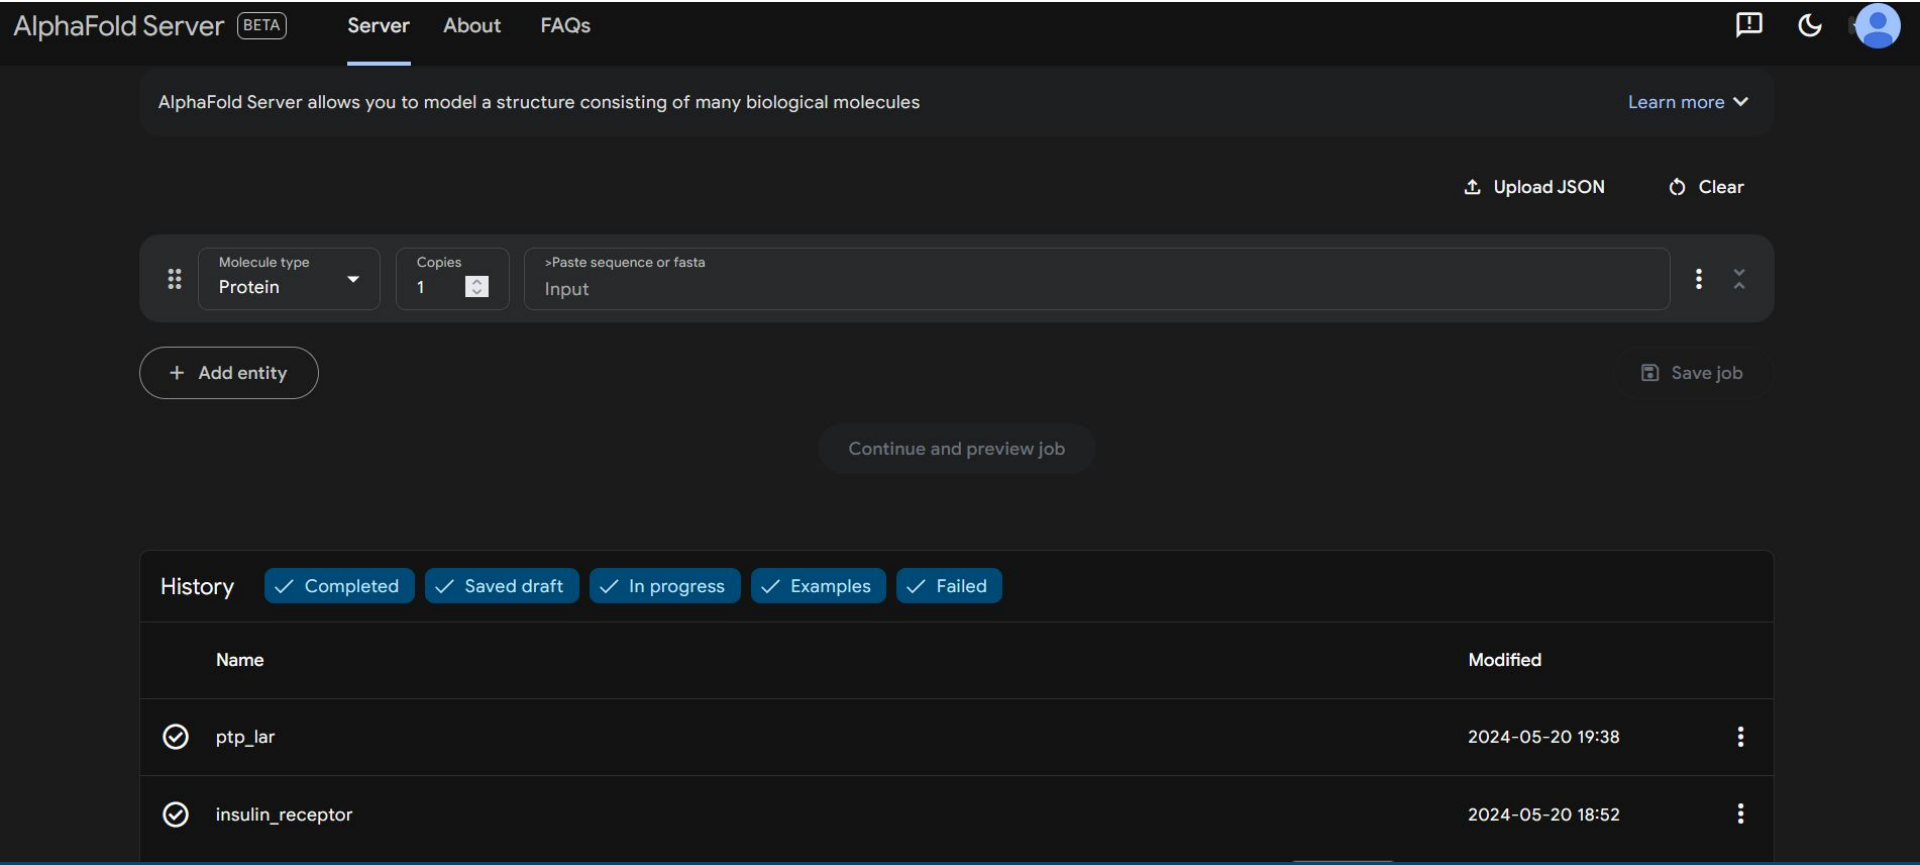
Refinamento com blocos Evoformer

05

Avaliação e Ajustes finais

Validação de acurácia e estereoquímica

Alpha Fold Server



Obtenção de modelos tridimensionais

261.584

Estruturas experimentalmente preditas no *PDB

1.062.058

Estruturas preditas computacionalmente no *PDB**

*Dados de 28 de outubro de 2026

04

Preparação das estruturas

Modelando as condições experimentais

Preparação das estruturas

Ao simular computacionalmente a interação entre átomos, é fundamental definir as condições experimentais que reproduzam o ambiente onde essa interação ocorreria naturalmente.



Preparação das Estruturas

Estruturas obtidas experimental ou computacionalmente requerem correção de erros comuns:

01

Átomos Ausentes

Falta de coordenadas para átomos da cadeia

02

Resíduos Incompletos

Aminoácidos com cadeias laterais faltantes

03

Cofatores e Íons

Inconsistências na coordenação química

04

Ligações & Coordenadas

Erros de geometria ou conectividade incorreta

Preparação das Estruturas

Além disso, é preciso considerar:

01

Adição de Hidrogênios

Inclusão de átomos de H na estrutura

02

Protonação e Carga dos Resíduos

Ajuste de estados de carga e pH

03

Remoção de Solventes

Eliminação de águas não estruturais

04

Posição e Carga de Cofatores

Verificação de cofatores e íons

05

Tautômeros e Ionização de Ligantes

Correção de estados de ionização

Preparação das Estruturas

A correta parametrização do sistema é essencial para garantir bons resultados

> *“Todos os modelos estão errados, alguns são úteis”*
> **— George Box**

LEMBRE-SE

Os experimentos de modelagem molecular são baseados nas leis da física, especialmente nas da mecânica clássica.

Por isso, é fundamental que os **tipos de átomos e suas cargas estejam devidamente definidos**.

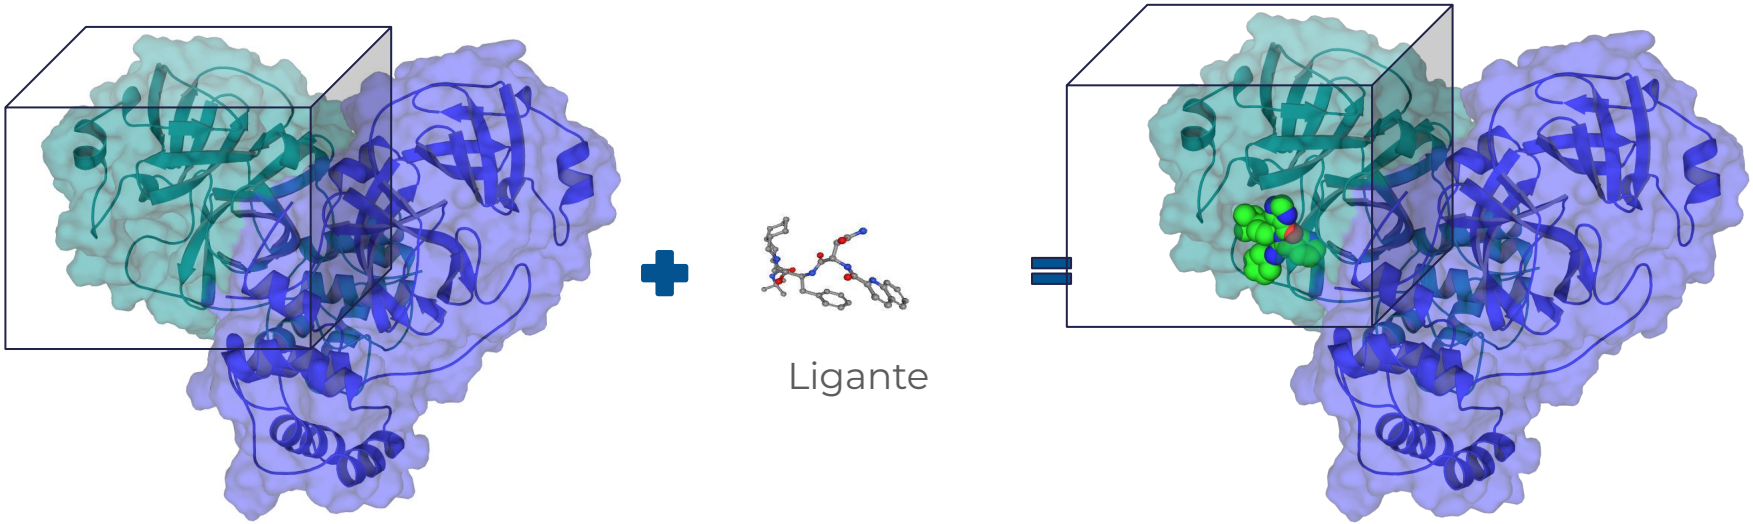
05

Simulações moleculares

Realizando experimentos moleculares

Docking molecular

Previsão dos detalhes do reconhecimento molecular receptor-ligante



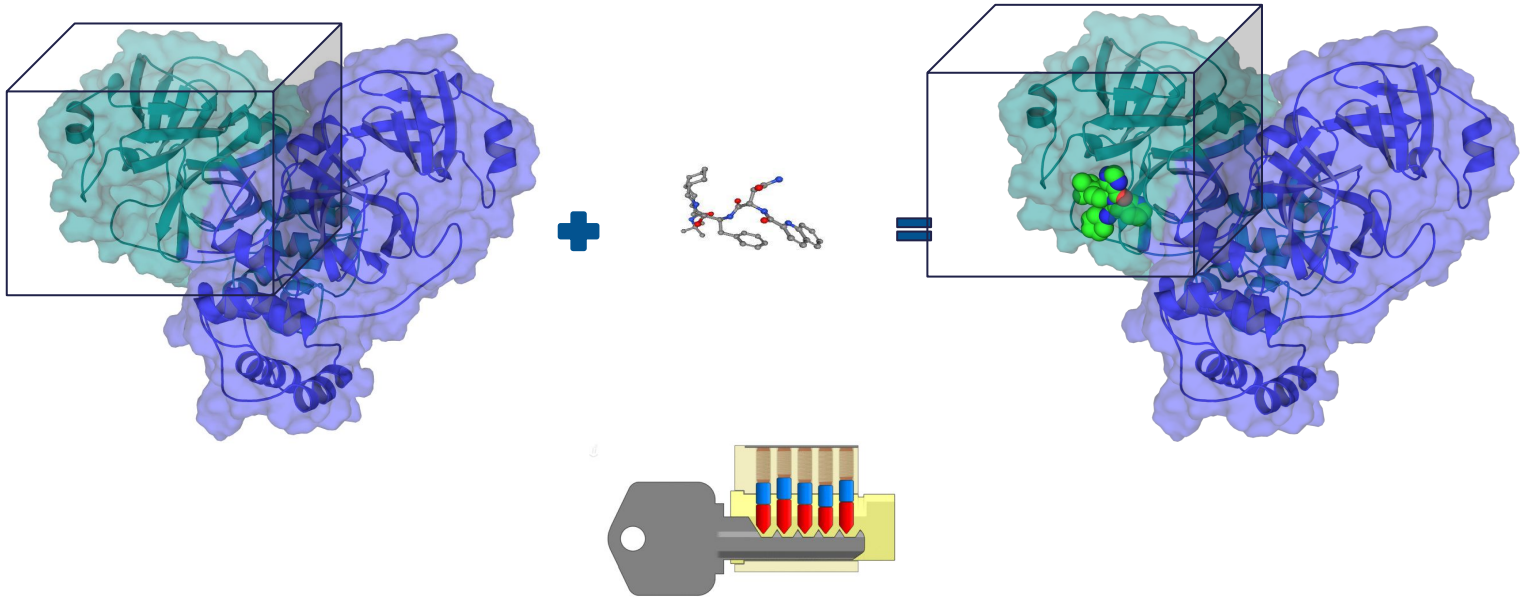
Receptor

Ligante

Complexo
proteína-ligante

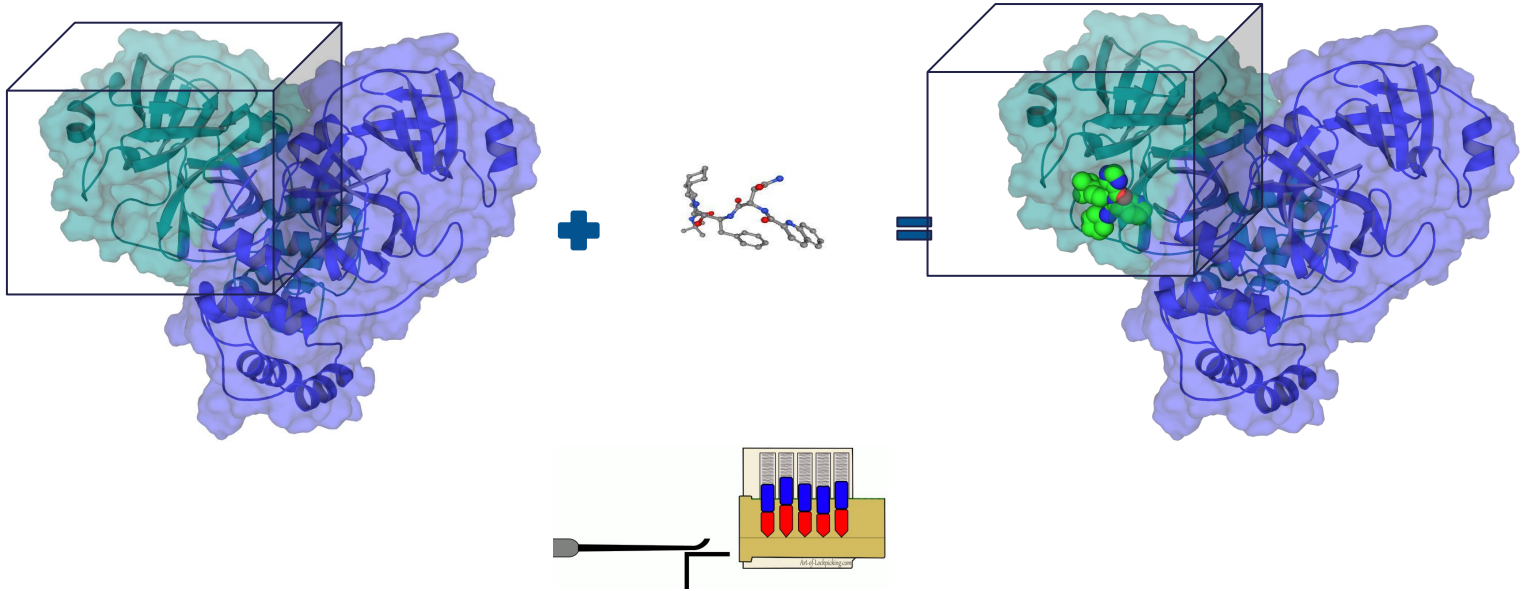
Docking molecular

Baseado no modelo chave-fechadura, proposto por Emil Fischer (1894)



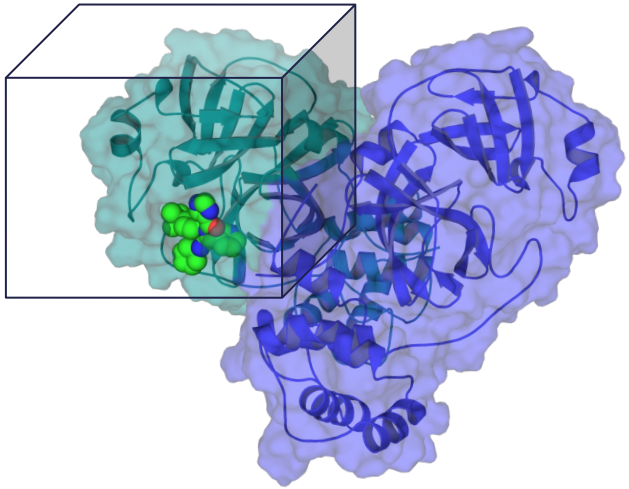
Docking molecular

Baseado no modelo chave-fechadura, proposto por Emil Fischer (1894)



Docking molecular

Previsão dos detalhes do reconhecimento molecular receptor-ligante

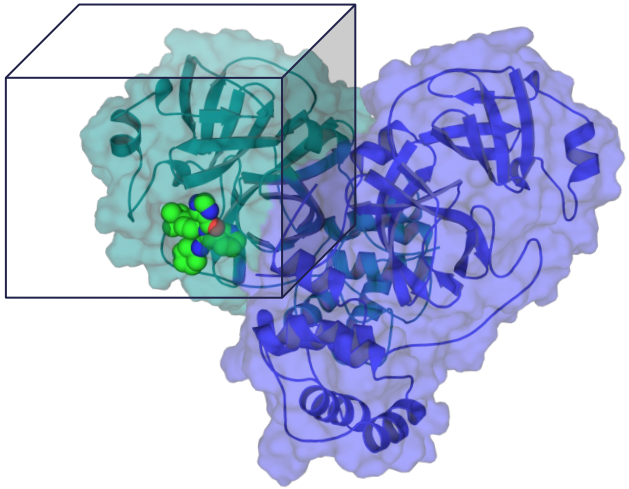


Dois principais componentes:

- Método de busca;
- Função de Avaliação;

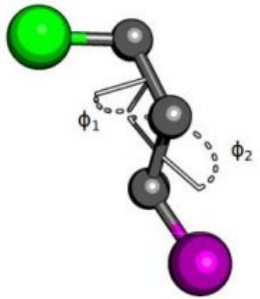
Docking molecular

Previsão dos detalhes do reconhecimento molecular receptor-ligante



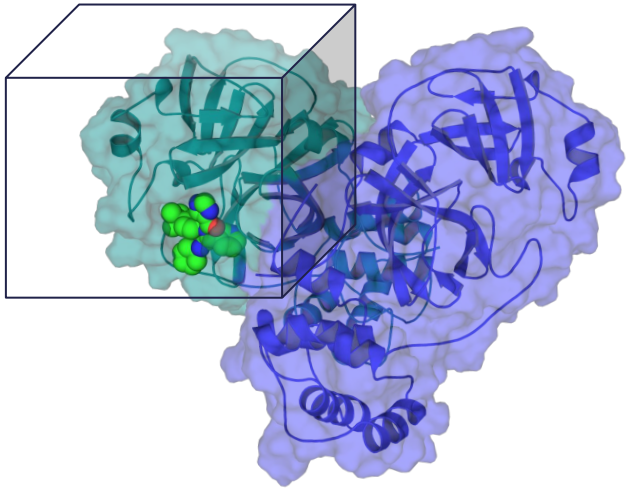
Dois principais componentes:

- Método de busca;



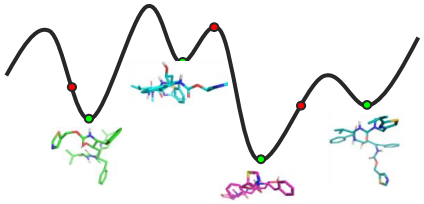
Docking molecular

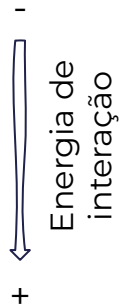
Previsão dos detalhes do reconhecimento molecular receptor-ligante



Dois principais componentes:

- Função de Avaliação;





Triagem Virtual: docking em larga escala

Identifica compostos promissores para interagir com um alvo biológico

01. Triagem Molecular

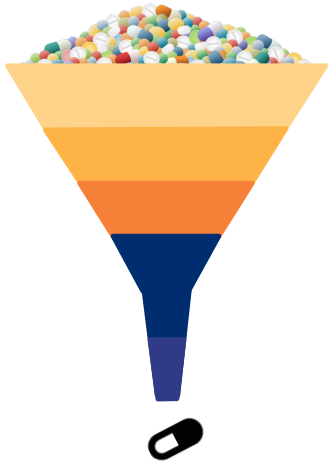
Docking automatizado de milhares de moléculas químicas contra o receptor biológico selecionado.

02. Alto Custo

Execução de milhares de simulações com processamento de alta performance e custo computacional.

03. Filtragem Virtual & Seleção de Compostos

“Funil” para refinar, priorizar e selecionar as estruturas moleculares de maior afinidade e estabilidade termodinâmica para as etapas experimentais posteriores in vitro.



Triagem Virtual: docking em larga escala

Identifica compostos promissores para interagir com um alvo biológico

01. Triagem Molecular

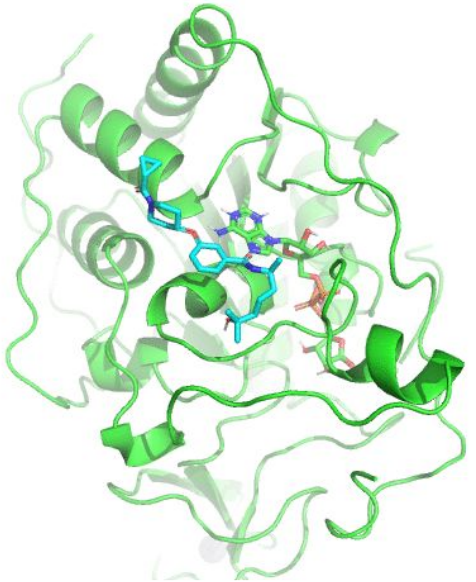
Docking automatizado de milhares de moléculas químicas contra o receptor biológico selecionado.

02. Alto Custo

Execução de milhares de simulações com processamento de alta performance e custo computacional.

03. Filtragem Virtual & Seleção de Compostos

“Funil” para refinar, priorizar e selecionar as estruturas moleculares de maior afinidade e estabilidade termodinâmica para as etapas experimentais posteriores in vitro.



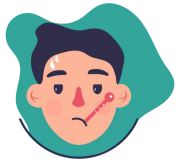
Reposicionamento de fármacos





Medicamentos conhecidos e aprovados por agências reguladoras

Indicação original



Doença A

Nova Indicação



Doença B

Identificação de novos alvos para medicamentos conhecidos

Dinâmica Molecular

Simulação do comportamento de átomos e moléculas ao longo do tempo com base na física clássica

01. Alto Custo

Exige infraestrutura de processamento massivo e alto custo computacional para simular os sistemas.

02. Previsão Temporal

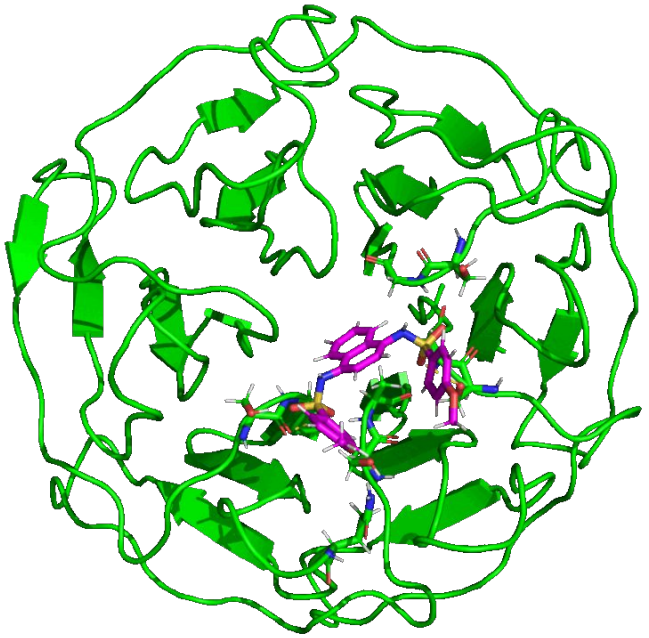
Excelente capacidade de prever a trajetória e o comportamento dinâmico do sistema molecular ao longo do tempo.

03. Estabilidade

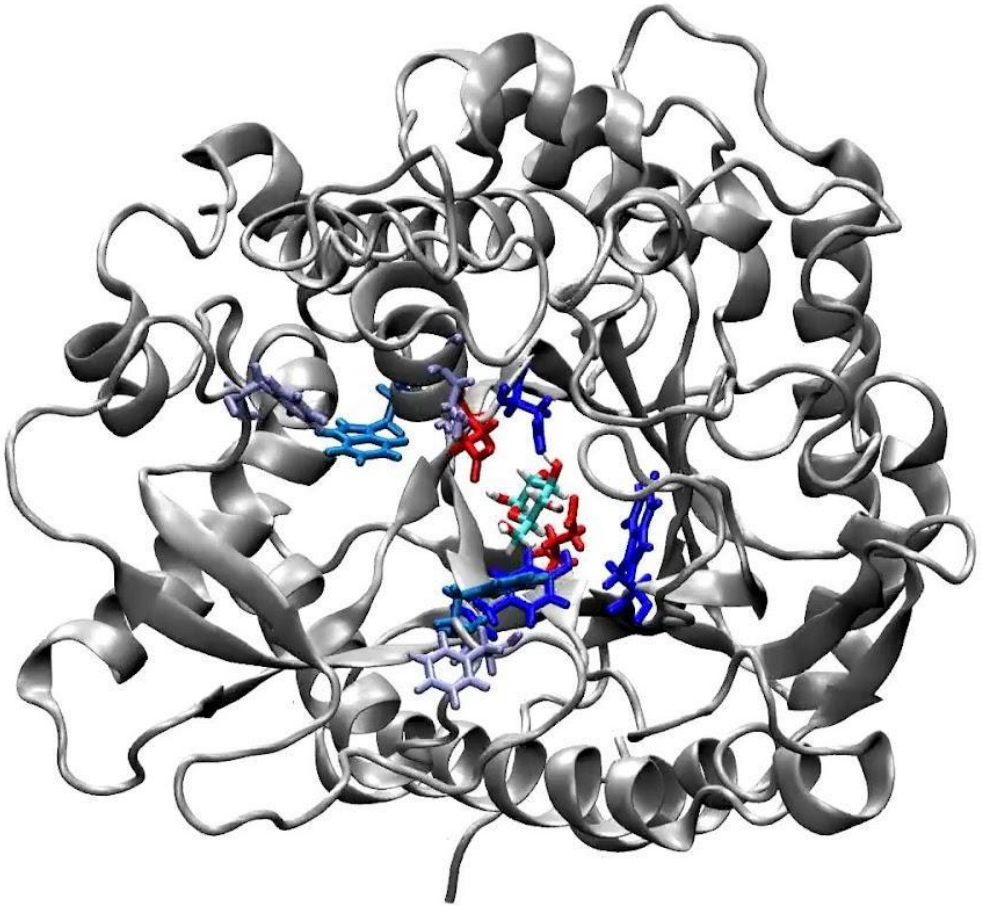
Estimação precisa da estabilidade termodinâmica e da energia livre de ligação do complexo receptor-ligante.

04. Volume de Dados

Gera uma grande quantidade de dados complexos que requerem ferramentas robustas de análise e triagem.



https://abeebyekeen.com/chaperong-tutorial-3-keap1kelchdomain-ligand-complex/



Predição de Propriedades ADMET

Triagem computacional acelerada de parâmetros farmacocinéticos e de toxicidade in silico

A - Absorção

Predição da permeabilidade intestinal, solubilidade aquosa e afinidade por transportadores como a Glicoproteína-P, antecipando a taxa de entrada no organismo.

D - Distribuição

Avaliação do volume de distribuição, taxa de ligação a proteínas plasmáticas (como albumina) e a capacidade de transpor a barreira hematoencefálica (BHE).

M/E - Metabolismo & Excreção

Identificação de sítios de metabolização pelas enzimas do Citocromo P450 (CYP) e estimativa da depuração (clearance) renal ou hepática dos compostos.

T - Toxicidade

Modelagem preditiva de efeitos adversos severos, incluindo mutagenicidade (teste de Ames), carcinogenicidade, hepatotoxicidade e bloqueio de canais hERG.

Inovação Farmacêutica com IA

Acelerando a descoberta de novas terapias moleculares de alta precisão

01

Design Inteligente de Fármacos

A inteligência artificial remodelou drasticamente a busca por novos compostos bioativos, permitindo a análise simultânea de propriedades ADMET essenciais em frações de segundos.

02

Triagem Virtual em Escala

Simulações de acoplamento molecular guiadas por aprendizado profundo avaliam bibliotecas químicas gigantescas, mitigando os gargalos físicos tradicionais do desenvolvimento científico.

03

Medicina Personalizada

A identificação robusta de biomarcadores moleculares pavimenta o caminho definitivo rumo a tratamentos individualizados de alta eficácia terapêutica.

IA na descoberta de fármacos

New machine learning and physics-based scoring functions for drug discovery

Isabella A. Guedes, André M. S. Barreto, Diogo Marinho, Eduardo Krempser, Mélaine A. Kuenemann, Olivier Sperandio, Laurent E. Dardenne ✉ & Maria A. Miteva ✉

Scientific Reports **11**, Article number: 3198 (2021) | Cite this article

IA na descoberta de fármacos

New machine learning and physics-based scoring functions for drug discovery

Isabella A. Guedes, André M. S. Barreto, Diogo Marinho, Eduardo Krempser, Mélaine A. Kuenemann, Olivier Sperandio, Laurent E. Dardenne & Maria A. M

Scientific Reports **11**, Article number: 3198 (202

SOFTWARE Open Access

GNINA 1.0: molecular docking with deep learning

Andrew T. McNutt[1], Paul Francoeur[1], Rishal Aggarwal[2], Tomohide Masuda[1], Rocco Meli[3], Matthew Ragoza[1], Jocelyn Sunseri[1] and David Ryan Koes[1*]

IA na descoberta de fármacos

New machine learning and physics-based scoring functions for drug discovery

Isabella A. Guedes, André M. S. Barreto, Diogo Marinho, Eduardo Krempser, Mélaine A. Kuenemann, Olivier Sperandio, Laurent E. Dardenne & Maria A. Miteva

Scientific Reports **11**, Article number: 3198 (2021) Cite this article

SOFTWARE Open Access

GNINA 1.0: molecular docking with deep learning

ew Ragoza[1],

MACHINE LEARNING AND DEEP LEARNING | January 25, 2021

Accelerating *De Novo* Drug Design against Novel Proteins Using Deep Learning

Sowmya Ramaswamy Krishnan, Navneet Bung, Gopalakrishnan Bulusu*, and Arijit Roy*

IA na descoberta de fármacos

New machine learning and physics-based scoring functions for drug discovery

Isabella A. Guedes, André M. S. Barreto, Diogo Marinho, Eduardo Krempser, Mélaine A. Kuenemann, Olivier Sperandio, Laurent E. Dardenne & Maria A. Miteva

Scientific Reports **11**, Article number: 3198 (2021) Cite this article

SOFTWARE Open Access

GNIN
learni

MACHINE LEARNING AND DEEP LEARNING | January 28, 2021

Accelerating *De Novo* Drug Design aga

Sowmya Ramaswamy Krishnan, Navneet Bung, Gopalakrishnan Bulusu*, ar

Andrew T. M
Jocelyn Suns

nature protocols

PROTOCOL

https://doi.org/10.1038/s41596-021-00659-2

Check for updates

Artificial intelligence-enabled virtual screening of ultra-large chemical libraries with deep docking

Francesco Gentile[1], Jean Charle Yaacoub[1,3], James Gleave[1,3], Michael Fernandez[1], Anh-Tien Ton[1], Fuqiang Ban[1], Abraham Stern[2] and Artem Cherkasov[1]

IA na descoberta de fármacos

New machine learning and physics-based scoring

nature biotechnology

Review article

https://doi.org/10.1038/s41587-024-02127-0

Machine learning for functional protein design

Received: 1 July 2023

Accepted: 5 January 2024

Published online: 15 February 2024

Pascal Notin[1,2,5] ✉, Nathan Rollins[3,5] ✉, Yarin Gal[2], Chris Sander[1,4] & Debora Marks[1,4] ✉

Open Access

ng with deep

PROTOCOL

https://doi.org/10.1038/s41596-021-00659-2

de Masuda[1], Rocco Meli[3], Matthew Ragoza[1],

Check for updates

-enabled virtual screening of ultra-large chemical libraries with deep docking

Francesco Gentile[1], Jean Charle Yaacoub[1,3], James Gleave[1,3], Michael Fernandez[1], Anh-Tien Ton[1], Fuqiang Ban[1], Abraham Stern[2] and Artem Cherkasov[1] ✉

IA na descoberta de fármacos

New machine learning and physics-based functions for drug discovery

nature biotechnology

Isabella A. Guedes, André M. S. Barreto, Diogo Marinho, Eduardo Krempser, Mé

Review article

Machine learning for functional protein design

Scientific Reports | (2021) | Cite this article

GNINA 1.0: m… learning

nature protocols

PROTOCOL

https://doi.org/10.1038/s41596-021-00659-2

Check for updates

Received: 1 July 2023

Accepted: 5 January 2024

Pascal Notin, Nathan Rollins, Yarin Gal, Chris Sander & Debora Marks

MACHINE LEARNING AND DEEP LEARNING | Sunday 28, 2024

Jocelyn Sunseri, David Ryan Koes

Accelerating *De Novo* Drug Design against Novel Proteins Using Deep Learning

Sowmya Ramaswamy Krishnan, Navneet Bung, Gopalakrishnan Bulusu*, and Arijit Roy*

A… intelligence-enabled virtual screening of ultra-large chemical libraries with deep docking

Francesco Gentile, Jean Charle Yaacoub, James Gleave, Michael Fernandez, Anh-Tien Ton, Fuqiang Ban, Abraham Stern and Artem Cherkasov

Structural bioinformatics

ADMET-AI: a machine learning ADMET platform for evaluation of large-scale chemical libraries

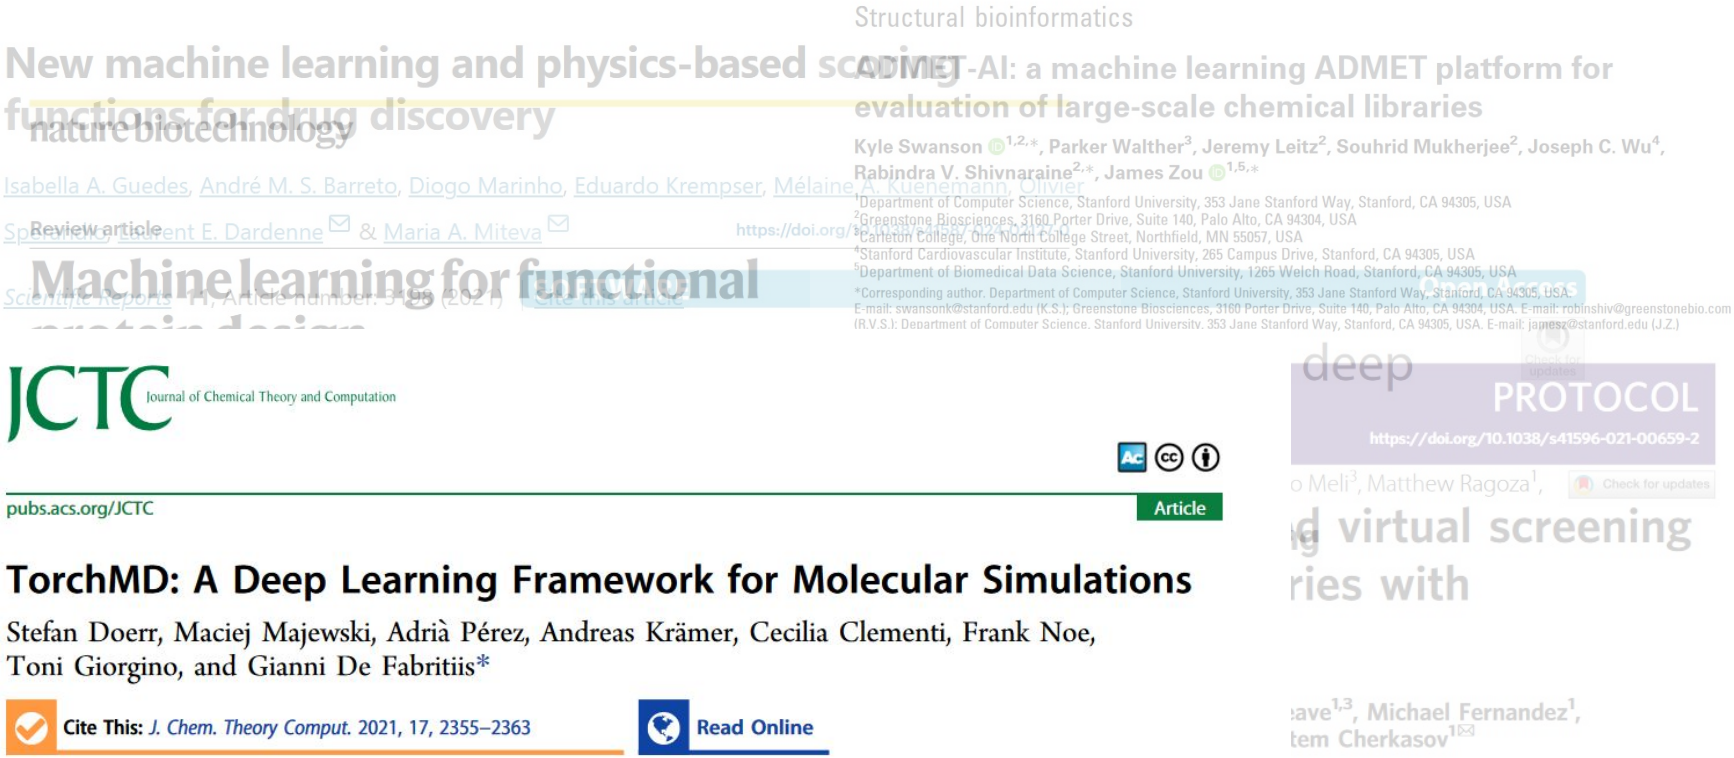
Kyle Swanson [1,2,*], Parker Walther[3], Jeremy Leitz[2], Souhrid Mukherjee[2], Joseph C. Wu[4], Rabindra V. Shivnaraine[2,*], James Zou [1,5,*]

[1]Department of Computer Science, Stanford University, 353 Jane Stanford Way, Stanford, CA 94305, USA
[2]Greenstone Biosciences, 3160 Porter Drive, Suite 140, Palo Alto, CA 94304, USA
[3]Carleton College, One North College Street, Northfield, MN 55057, USA
[4]Stanford Cardiovascular Institute, Stanford University, 265 Campus Drive, Stanford, CA 94305, USA
[5]Department of Biomedical Data Science, Stanford University, 1265 Welch Road, Stanford, CA 94305, USA

*Corresponding author. Department of Computer Science, Stanford University, 353 Jane Stanford Way, Stanford, CA 94305, USA.
E-mail: swansonk@stanford.edu (K.S.); Greenstone Biosciences, 3160 Porter Drive, Suite 140, Palo Alto, CA 94304, USA. E-mail: robinshiv@greenstonebio.com (R.V.S.); Department of Computer Science, Stanford University, 353 Jane Stanford Way, Stanford, CA 94305, USA. E-mail: jamesz@stanford.edu (J.Z.)

Associate Editor: Alfonso Valencia

IA na descoberta de fármacos



Structural bioinformatics

ADMET-AI: a machine learning ADMET platform for evaluation of large-scale chemical libraries

Kyle Swanson[1,2,*], Parker Walther[3], Jeremy Leitz[2], Souhrid Mukherjee[2], Joseph C. Wu[4], Rabindra V. Shivnaraine[2,*], James Zou[1,5,*]

[1]Department of Computer Science, Stanford University, 353 Jane Stanford Way, Stanford, CA 94305, USA
[2]Greenstone Biosciences, 3160 Porter Drive, Suite 140, Palo Alto, CA 94304, USA
[3]Carleton College, One North College Street, Northfield, MN 55057, USA
[4]Stanford Cardiovascular Institute, Stanford University, 265 Campus Drive, Stanford, CA 94305, USA
[5]Department of Biomedical Data Science, Stanford University, 1265 Welch Road, Stanford, CA 94305, USA

*Corresponding author. Department of Computer Science, Stanford University, 353 Jane Stanford Way, Stanford, CA 94305, USA. E-mail: swansonk@stanford.edu (K.S.); Greenstone Biosciences, 3160 Porter Drive, Suite 140, Palo Alto, CA 94304, USA. E-mail: robinshiv@greenstonebio.com (R.V.S.); Department of Computer Science, Stanford University, 353 Jane Stanford Way, Stanford, CA 94305, USA. E-mail: jamesz@stanford.edu (J.Z.)

JCTC Journal of Chemical Theory and Computation

pubs.acs.org/JCTC Article

TorchMD: A Deep Learning Framework for Molecular Simulations

Stefan Doerr, Maciej Majewski, Adrià Pérez, Andreas Krämer, Cecilia Clementi, Frank Noe, Toni Giorgino, and Gianni De Fabritiis*

Cite This: J. Chem. Theory Comput. 2021, 17, 2355−2363 Read Online

Obrigada!

@: almk.karl@gmail.com
https://www.linkedin.com/in/aluizakarl/
https://github.com/aluizakarl